

ETAPA 1 — EXPLORAÇÃO DO DATASET

Disciplina: Ciência de Dados

Professor: Breno Holanda

Caso: Clínica Médica

Dataset: grupo2_clinica.csv

Alunas: Fernanda Gabrielli, Livia Janine, Maria Fernanda, Clara Heloisa.

1. Inspeção Inicial do Dataset

Foram executados os seguintes comandos de exploração:

- `df.shape`
- `df.dtypes`
- `df.head()`
- `df.isnull().sum()`
- `df.duplicated().sum()`

Resultado da inspeção

- Total de registros: **2860**
- Total de colunas: **13**
- Registros duplicados encontrados: **60**

O dataset contém informações de atendimentos realizados em uma clínica médica, incluindo dados dos pacientes, consultas, convênios, especialidades e valores cobrados.

2. Descrição das Colunas

Coluna	Tipo de dado	Descrição
id_atendimento	object	Identificador único do atendimento
data_atendimento	object	Data em que o atendimento foi realizado

id_paciente	object	Identificador único do paciente
nome_paciente	object	Nome completo do paciente
idade	float64	Idade do paciente
sexo	object	Sexo do paciente
especialidade	object	Especialidade médica do atendimento
medico	object	Médico responsável pela consulta
convenio	object	Convênio utilizado pelo paciente
diagnostico	object	Diagnóstico registrado
valor_consulta	float64	Valor cobrado pela consulta
retorno	object	Indica se houve retorno do paciente
duracao_minutos	int64	Duração da consulta em minutos

3. Valores Nulos Identificados

Coluna	Quantidade de Nulos
--------	---------------------

idade	35
sexo	386
diagnostico	939
valor_consulta	77
retorno	370

Os valores ausentes deverão ser tratados durante a etapa de ETL para evitar distorções nas análises e indicadores do dashboard.

4. Principais Problemas de Qualidade Encontrados

Problema 1 — Registros Duplicados

Foram encontrados *60 registros duplicados*.

Caso esses registros não sejam removidos, haverá aumento artificial na quantidade de atendimentos e também na receita calculada da clínica.

Problema 2 — Idades Inválidas

Foram identificadas *69 idades impossíveis*, incluindo valores negativos e extremamente elevados.

Exemplos encontrados:

- Idade mínima: **-5 anos**
- Idade máxima: **999 anos**

Esses valores não representam situações reais e podem comprometer análises de faixa etária.

Problema 3 — Convênios com Grafias Diferentes

Foram encontradas diversas formas de representar o mesmo convênio:

- Unimed
- UNIMED
- unimed
- Particular
- particular

Sem padronização, a receita de um mesmo convênio ficaria dividida em várias categorias diferentes.

Problema 4 — Especialidades com Inconsistências

Foram encontradas variações de escrita para a mesma especialidade:

- CARDIOLOGIA
- Cardiologia
- neurologia
- Neurologia
- Gineco
- Ginecologia
- clinica geral
- Clínica Geral

Essas diferenças dificultam análises por especialidade.

Problema 5 — Campo Retorno sem Padronização

Foram encontrados vários formatos para representar a mesma informação:

- S
- Sim
- sim
- N
- Não
- nao

Sem padronização, não seria possível calcular corretamente a taxa de retorno dos pacientes.

Problema 6 — Campo Sexo com Múltiplas Grafias

Foram identificadas as seguintes variações:

- M
- m
- Masculino
- F
- f
- Feminino

Essas diferenças criam categorias duplicadas durante as análises.

Problema 7 — Datas em Formatos Diferentes

A coluna **data_atendimento** apresenta vários formatos:

- 01.01.2025
- 09/02/2024
- 2025-03-01
- 10-07-2023
- 01-23-2026

Essa inconsistência impede análises temporais e extração correta de mês e ano.

5. Perguntas de Negócio

Pergunta 1

Qual faixa etária concentra mais atendimentos na clínica?

Colunas utilizadas

- idade
- id_atendimento

Justificativa

A coluna idade será utilizada para criar a variável derivada faixa_etaria, permitindo agrupar os pacientes por categoria. O campo id_atendimento será utilizado para contabilizar o número de atendimentos realizados em cada faixa etária.

Pergunta 2

Qual convênio gera mais receita para a clínica?

Colunas utilizadas

- convenio
- valor_consulta

Justificativa

A coluna convenio permitirá identificar o plano utilizado pelo paciente. A coluna valor_consulta será utilizada para calcular a receita total gerada por cada convênio, possibilitando identificar qual deles possui maior impacto financeiro para a clínica.

Conclusão

A exploração inicial revelou diversos problemas de qualidade de dados, incluindo valores ausentes, registros duplicados, idades inválidas, categorias com grafias inconsistentes e formatos diferentes de data. Esses problemas poderiam comprometer diretamente a análise dos dados e a construção do dashboard. Por esse motivo, será necessária uma etapa de limpeza, padronização e enriquecimento dos dados antes da geração dos indicadores e visualizações que responderão às perguntas de negócio do projeto.